



Education

太原理工大学 (211) - 软件工程 软件学院

2022.09 - 2026.07

目前已保研至 中国科学技术大学 (985)

专业排名: 2/1519(专业前0.2%) GPA: 4.54/5.00 英语水平: CET-4 (544) CET-6 (508)

荣誉奖励: 第十五届蓝桥杯国家优秀奖、创祿杯课外学术国家级铜奖、第七届“青欧”奖优秀人才奖 (2%)

Experience

百度在线网络技术有限公司-Python 后端开发工程师

2025.11 - 2026.02

工作内容及成果:

①参与了群内无人值守的搭建, 从**快照缓存优化为Kafka**实现各阶段的**提醒、预警、上升**, 并且制作**群聊置顶卡片**跟踪实时进度, MAU 达到1000+, 收到多数RD的好评

②使用Milvus存储不同工具和Agent的使用规范, 对**Query 进行优化**(查询转化、意图识别、HyDE), 提高了短查询的检索效果, **MRR指标**从 0.50 提高至**0.72**

③实现了意图精准下发与多Agent协同(如计费、品牌、分RD等)之间的连通, 支持**群聊场景中直接调起主Agent**及任意子Agent, 累计**接入5个子agent, 13+工具**, 累计调用量约400次, 准确率达80%+

杰普软件科技有限公司-Java 后端开发工程师

2025.08 - 2025.10

工作内容及成果:

①运用**策略模式**处理消息处理架构, 实现文本/表情/文件等多类型消息的动态扩展能力, 系统核心模块符合开闭原则

②通过布隆过滤器解决了**缓存穿透**问题, 给不同的缓存设置随机TTL解决**缓存雪崩**问题, 使用互斥锁解决**缓存击穿**问题

③通过垂直分表以及冗余字段设计优化了5张主要业务表结构, 同时采用**延迟关联**进行深分页查询的优化实现, 将百万级查询耗时从分钟级降低至 500ms 以内

Projects

新能源车企业销售培训助手 技术栈: LlamaIndex、Milvus、LoRA、React、PostgreSQL、RAG、Agent、Docker

- 项目介绍: 构建了融合本地知识库检索与实时网络搜索的多模态智能销售Agent, 帮助新能源汽车企业提升一线销售的专业度
- ①RAG检索构建: 利用**Llamaindex + Milvus + BGE**搭建知识库检索系统, 使用BM25与向量相似度**混合召回**, 对DeepSeek-R1-Distill-Qwen-1.5B进行**LoRA微调**以**优化意图识别**降低成本与延时, 最终Recall@10从53%提升至89%
- ②WebSearch组件: 通过Serper Search API获取竞品/政策/市场/行业实时信息, 采用**查询扩展**与关键词拆解, 筛选Top50网页信息, 去重并基于相关度和时间权重**二次过滤**至Top32
- ③多Agent工作流: 使用**ReAct + Reflection + Memory**机制, 将用户需求拆解给不同Agent执行; Reflection模块能够对检索结果进行思考与修正, Memory模块保留上下文, 实现类人销售对复杂问题的深度回答
- ④问答生成与后处理: 在给出回答前, 综合用户Query、拓展信息、检索问答对, 由大模型统一生成Markdown格式的回复

Research

1) MDFformer: A Multi-scale Dual-modal Fusion Transformer for Semantic Segmentation

三区期刊一作收录

• 提出了用于多模态遥感语义分割的模型, 可以更加高效的处理多尺度信息以及多模态对齐, 同时实现了精度-效率的平衡

2) Kinship Verification via Angular Margin Metric Learning and Gender Relation Discriminating Adversarial Decoupling C类会议三作收录

• 通过对抗性的性别解耦和基于角边度量学习, 更加关注亲属的专属特征, 提高了面部图像进行亲属验证任务的准确度

Skills

- 工程开发**: 掌握Java、Python、Vue3、Linux、Redis、MySQL、消息队列等核心知识, 能够运用到大模型应用开发实践当中
- 设计模式**: 熟悉常见的设计模式, 如工厂模式、代理模式、装饰器模式、策略模式等内容
- 向量数据库**: 掌握Elasticsearch (BM25)、Milvus (向量数据库)、Cross-Encoder (Rerank), 了解数据库的差异以及选型
- 文档解析与切块**: 掌握PyMuPDF/PPTX Python 解析、PaddleOCR、表格识别, 以及Chunk切分的手段(规则、语义)
- LLM Engineering**: 掌握Transformer的信息流动与推理过程、Advanced RAG优化手段、多种微调策略(LoRA、QLoRA、Adapter)、RLHF核心算法(PPO、DPO、GRPO)以及RW的训练方法